

LAPORAN PROYEK AKHIR
Analisis Pasar Kerja Indonesia

Implementasi Big Data Pipeline



Oleh:

Nadhif Rif'at Rasendriya

235150201111074

UNIVERSITAS BRAWIJAYA
FAKULTAS ILMU KOMPUTER
2026

DAFTAR ISI

BAB 1 - PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Tujuan.....	2
1.3 Ruang Lingkup.....	2
BAB 2 - Implementasi: Pengumpulan Data (Extract).....	3
2.1 Alur Kerja Kode (Workflow).....	3
2.2 Dokumentasi Proses.....	4
Fase A: Ekstrak Lowongan AI Engineer.....	4
Fase B: Ekstrak Multi-Lowongan Finance.....	4
Fase C: Ekstrak Lowongan Finance dari Glints.....	5
BAB 3 - Implementasi: Preprocessing & Veracity (Transform).....	7
3.1 Masalah Kualitas Data (Dirty Data).....	7
3.2 Teknik Data Cleaning yang Diterapkan.....	7
3.3 Perbandingan Sebelum dan Sesudah Cleaning.....	7
BAB 4 - Implementasi: Analisis & Value (Exploratory Data Analysis).....	9
4.1 Visualisasi Data Distribusi (EDA).....	9
4.2 Analisis Teks (Frekuensi Kata).....	10
BAB 5 - KESIMPULAN.....	11
5.1 Rangkuman Pipeline.....	11
5.2 Limitasi & Rekomendasi Pengembangan.....	11
LAMPIRAN.....	12

BAB 1 - PENDAHULUAN

1.1 Latar Belakang

Di era digitalisasi saat ini, informasi pasar tenaga kerja telah bertransisi sepenuhnya dari media konvensional menuju portal lowongan kerja daring (*job portals*). Fenomena ini menciptakan tumpukan data rekrutmen yang sangat masif, yang secara potensial dapat dianalisis untuk memahami tren industri, permintaan keahlian (*skill demand*), hingga pemetaan kompensasi finansial secara makro. Namun, pemanfaatan data ini dihadapkan pada tantangan fragmentasi; informasi tersebar di berbagai platform yang saling terisolasi tanpa adanya standar format periklanan yang seragam.

Dari perspektif Analitika Big Data, tantangan ini secara langsung merepresentasikan karakteristik **Variety** (keanekaragaman sumber, struktur, dan format data) serta **Veracity** (tingkat kebersihan, konsistensi, dan validitas data). Secara teknis, platform modern pencari kerja terkemuka (seperti Karir.com dan Glints.com) menerapkan arsitektur web dinamis berbasis *Client-Side Rendering* (CSR) dengan *Document Object Model* (DOM) yang kerap diobfuskasi (*obfuscated*) atau diacak. Tingkat kerumitan bertambah dengan adanya sistem proteksi keamanan *Anti-Bot* berlapis (seperti *Cloudflare Turnstile*) di sisi server, yang menjadikan proses akuisisi data tidak bisa lagi dilakukan dengan metode *crawling* HTML statis tradisional.

Oleh karena itu, diperlukan sebuah arsitektur *pipeline* rekayasa data (*Data Engineering*) yang tangguh dan komprehensif. Proyek akhir ini digagas untuk merancang serta mengimplementasikan sistem ETL (*Extract, Transform, Load*) secara *end-to-end*. Sistem ini didesain untuk mampu melakukan *dynamic web scraping*, menembus proteksi keamanan antarmuka, mengekstraksi data semi-terstruktur dari *layout* yang berbeda, dan menyelaraskan anomali teks (*dirty data*) menjadi satu *master dataset* yang terstandardisasi. Hasil dari proses ini diharapkan dapat menjembatani jurang antara data mentah yang kotor di internet dengan wawasan (*actionable insights*) yang bernilai (*Value*).

1.2 Tujuan

Proyek akhir ini bertujuan untuk membangun sebuah purwarupa *pipeline* rekayasa data *end-to-end* (ETL - *Extract, Transform, Load*) guna mengotomatisasi pengumpulan, pembersihan, integrasi, hingga visualisasi data lowongan kerja dari dua platform yang memiliki struktur berbeda (Karir.com dan Glints.com).

1.3 Ruang Lingkup

- **Pengumpulan Data:** *Web scraping* dinamis untuk profil lowongan "Medical Artificial Intelligence (AI) Engineer" dan "Finance" di Karir.com dan Glints.com.
- **Pengolahan Data:** Menerapkan standardisasi untuk mengatasi *dirty data* (nilai kosong yang tidak seragam dan format numerik yang kotor).
- **Analisis Awal (EDA):** Menggali *insight* frekuensi kata kunci dan distribusi atribut melalui visualisasi data.

BAB 2 - Implementasi: Pengumpulan Data (*Extract*)

2.1 Alur Kerja Kode (Workflow)

Proses ekstraksi data ini menggunakan teknik *Web Scraping* dinamis dengan Selenium. Alur kerjanya adalah sebagai berikut:

1. **Inisialisasi Environment:** Menginstal library google colab selenium untuk menjalankan browser Chrome di server Google Colab tanpa memerlukan pengaturan manual Driver yang rumit.
2. **Navigasi Web:** Menggunakan Selenium untuk membuka URL spesifik dari Karir.com maupun Glints.com berdasarkan kata kunci pencarian.
3. **Pengolahan DOM:** Mengambil source code HTML halaman menggunakan `page_source` dan memprosesnya dengan BeautifulSoup.
4. **Ekstraksi Data (Visual Order Scraping):** Mengambil teks murni (`stripped_strings`) untuk menghindari kendala pada nama *class* HTML yang dinamis dan teracak.
5. **Pemetaan Atribut:** Mencocokkan teks yang didapat ke dalam 11 atribut wajib sesuai panduan teknis.
6. **Penyimpanan:** Mengonversi data ke dalam Pandas DataFrame dan mengeksportnya ke format CSV.

Alasan Pemilihan Metode (Selenium dan BeautifulSoup): Proses pengumpulan data tidak menggunakan metode API resmi (karena keterbatasan akses publik) atau metode *request* statis biasa (seperti library requests), melainkan menggunakan kombinasi Selenium dan BeautifulSoup dengan alasan teknis berikut:

- **Selenium untuk Penanganan Web Dinamis & Anti-Bot:** Platform modern seperti Karir.com dan Glints dibangun menggunakan framework JavaScript dinamis (seperti React). Konten detail lowongan (panel kanan) baru akan muncul ke dalam struktur HTML (DOM) setelah pengguna melakukan interaksi (klik) pada kartu lowongan di panel kiri. Selenium memungkinkan robot untuk menyimulasikan interaksi manusia (klik dan *scroll*) agar data muncul seutuhnya. Selain itu, Selenium dikonfigurasi dengan *User-Agent* khusus untuk menembus sistem proteksi Anti-Bot (seperti Cloudflare) yang sangat ketat pada situs Glints.


```

--- Initialized Chromedriver
loading halaman Finance...
Berhasil mendeteksi 12 lowongan potensial.
Berhasil menarik data ke-1: Finance Staff - Mataram
Berhasil menarik data ke-2: Finance Accounting Tax Supervisor
Berhasil menarik data ke-3: Microsoft Dynamics 365 Finance - technical consultant
Berhasil menarik data ke-4: Microsoft Dynamics AX / 365 ERP Finance and Operations Technical Staff
Berhasil menarik data ke-5: Finance Staff

```

	job_title	company_name	location	job_type	experience_level	education_req	salary_range	job_requirements	job_responsibilities	posted_date	source_platform
1	Finance Staff - Mataram	PT Enseval Putera Megatrading, Tbk	Mataram	Tidak Disebutkan	-	S1 - Akuntansi	-	Bachelor's Degree of Accounting Experienced ...	Handling various tasks related to maintaining ...	27 Februari 2026	Karir.com
2	Finance Accounting Tax Supervisor	PT Enseval Putera Megatrading, Tbk	Jakarta Timur	Tidak Disebutkan	5 tahun	S1 - Akuntansi	Rp 10 juta - Rp 11 juta/bulan	Bachelor/Master degree from Accounting Exper...	Responsible for full function of Finance, Acco...	27 Februari 2026	Karir.com
3	Microsoft Dynamics 365 Finance - technical con...	PT Daya Medika Pratama	Jakarta Pusat	Tidak Disebutkan	4 tahun	S1, D3 - Administrasi Bisnis (Keuangan), Akunt...	-	2 years in the following skill set: 1.Dynami...	1)Provide technical consultancy to clients for...	27 Februari 2026	Karir.com
4	Microsoft Dynamics AX / 365 ERP Finance and Op...	PT Daya Medika Pratama	Bandung	Tidak Disebutkan	5 tahun	S2, S1, D3 - Administrasi Bisnis (Keuangan), A...	Rp 6 juta - Rp 13 juta/bulan	Microsoft Dynamics AX, D365 F&O, X++, SSRS/ Po...	Demonstrates strong coding skill using Dynamic...	27 Februari 2026	Karir.com
5	Finance Staff	PT Enseval Putera Megatrading, Tbk	Mataram	Tidak Disebutkan	-	S1 - Akuntansi	-	Bachelor's Degree of Accounting Experienced ...	Handling various tasks related to maintaining ...	27 Februari 2026	Karir.com


Pada kolom '**job_type**' tertulis 'Tidak disebutkan', hal tersebut terjadi karena pada informasi lowongan kerja (sumber asli) memang tidak disebutkan oleh pemilik lowongan.

Fase C: Ekstrak Lowongan Finance dari Glints

Fase ini bertujuan untuk memperluas jangkauan sumber data dengan mengambil informasi posisi "Finance" dari platform Glints.com.

- **Aktivitas:** Melakukan pencarian menggunakan kata kunci "Finance" dan lokasi "All Cities/Provinces" di Glints. Robot melakukan *looping* untuk mengklik dan mengekstrak data 5 lowongan teratas.
- **Kendala:**
 1. **Sistem Anti-Bot (Cloudflare):** Akses bot secara bawaan langsung diblokir oleh Glints dengan menampilkan halaman verifikasi "Just a moment..."
 2. **Struktur Web Tanpa Label:** Berbeda dengan Karir.com, Glints tidak menggunakan label teks (seperti "Tingkat Pendidikan:"), melainkan langsung menampilkan nilai dengan *icon* visual.
 3. **Teks Footer Masuk ke Data:** Karena metode mengambil seluruh teks di layar, atribut nama perusahaan sempat terisi teks hak cipta "© 2026 PT. Glints", dan lokasi terisi tombol "Kembali ke atas".
- **Solusi Tambahan:**
 - Menerapkan *User-Agent Spoofing* agar aktivitas robot dari Google Colab dikenali sebagai peramban Chrome Windows standar oleh Cloudflare.

- Menerapkan **Logika Heuristik Pintar**, yaitu mengenali data dari konteks kata (misal: jika mengandung kata "PT.", maka itu nama perusahaan; jika mengandung "tahun", maka itu pengalaman).
- Menerapkan **Teknik Isolasi/Mutilasi Teks**, di mana robot diprogram untuk menemukan letak judul di panel kanan, lalu secara otomatis "memotong" dan membuang teks menu panel kiri dan *footer* web bagian bawah agar ekstraksi tetap fokus.
- **Hasil:** Berhasil mengekstrak 5 baris lowongan kerja dari Glints.
- **Output:** raw_dataset_finance_glints.csv.



BAB 3 - Implementasi: *Preprocessing & Veracity (Transform)*

Tahap pembersihan data ini difokuskan untuk menyelesaikan karakteristik **Veracity** pada Big Data, mengingat integrasi dari berbagai sumber otomatis mewariskan format penulisan yang tidak selaras (*dirty data*).

3.1 Masalah Kualitas Data (Dirty Data)

Dari tahap *Extract* (Pengumpulan Data), ketiga sumber data yang dikompilasi secara vertikal menyimpan anomali kualitas data pada *Master Dataset Mentah*:

1. **Format Missing Values Inkonsisten:** Terdapat variasi "N/A" dari Glints, "-" dari Karir.com, dan "Tidak Disebutkan".
2. **Kotoran Nominal Numerik:** Kolom gaji (*salary_range*) mengandung teks *hybrid* seperti "jt", spasi non-standar, atau penandaan "Gaji Tidak Ditampilkan" yang tidak terukur secara komputasi.

3.2 Teknik Data Cleaning yang Diterapkan

Kode program tambahan diimplementasikan menggunakan fungsi library Pandas dan NumPy:

- **Standardisasi Null:** Mengonversi seluruh wujud penanda kosong (seperti -, N/A, Tidak Disebutkan) menjadi format standar NaN (Not a Number).
- **Normalisasi Gaji:** Mengaplikasikan fungsi *custom* untuk mengganti token "jt" menjadi "juta", menghapus spasi anomali, dan menyeragamkan kalimat penolakan visibilitas gaji menjadi format seragam "Hidden by Employer".
- **Imputasi Pengalaman:** Memberlakukan pengisian format baku "Fresh Graduate / No Experience" untuk kolom level pengalaman (*experience_level*) yang kosong.

3.3 Perbandingan Sebelum dan Sesudah Cleaning

- **Sebelum (Raw Data):** Skema data tidak terpadu dan kotor. Data tidak valid jika diproses ke dalam model prediktif analitika maupun perangkat visualisasi.
- **Sesudah (Processed Data):** Menghasilkan berkas akhir *cleaned_dataset_tahap2.csv* di mana keseluruhan 11 kolom atribut telah terseragamkan. Kebenaran dan

konsistensi data (Veracity) kini dapat dipertanggungjawabkan untuk dianalisis lebih lanjut.

File 'cleaned_dataset_tahap2.csv' berhasil disimpan!												
	No	job_title	company_name	location	job_type	experience_level	education_req	salary_range	job_requirements	job_responsibilities	posted_date	source_platform
0	1	Medical Artificial Intelligence (AI) Engineer	PT Daya Medika Pratama	Bandung	Tidak Disebutkan	2 tahun	S2, S1, D3 - Ilmu Komputer, Manajemen Informat...	Rp 6 juta - Rp 10 juta/bulan	Skills and Qualifications Technical Expertis...	Responsibilities Design, develop, and implem...	9 Juni 2026	Karir.com
1	2	Finance Accounting & Tax	Minimal Diploma (D1 - D4)	Kab. Bekasi	Penuh Waktu	1-3 tahun	Minimal Diploma (D1 - D4)	Gaji Tidak Ditampilkan	NaN	NaN	Baru (< 2 minggu)	Glints
2	3	Finance Accounting & Tax	Minimal Diploma (D1 - D4)	Kab. Bekasi	Penuh Waktu	1-3 tahun	Minimal Diploma (D1 - D4)	Gaji Tidak Ditampilkan	NaN	NaN	Baru (< 2 minggu)	Glints
3	4	Finance / Bagian Keuangan.	Minimal Sarjana (S1)	Jakarta Barat	Kontrak	1-3 tahun	Minimal Sarjana (S1)	Rp 5 juta-7 juta	NaN	NaN	Baru (< 2 minggu)	Glints
4	5	Manager Finance Accounting & Tax	Minimal Sarjana (S1)	Semarang	Penuh Waktu	3-5 tahun	Minimal Sarjana (S1)	Rp 5 juta	NaN	NaN	Baru (< 2 minggu)	Glints
5	6	Manager Finance Accounting Tax	Minimal Sarjana (S1)	Jakarta Barat	Kontrak	1-3 tahun	Minimal Sarjana (S1)	Rp 10 juta-12 juta	NaN	NaN	Baru (< 2 minggu)	Glints


BAB 4 - Implementasi: Analisis & Value (*Exploratory Data Analysis*)

Karakteristik **Value** pada Big Data ditunjukkan dari kemampuan mengubah tumpukan baris teks yang telah dibersihkan menjadi wawasan (*insight*) visual yang dapat dibaca dan diinterpretasikan.

4.1 Visualisasi Data Distribusi (EDA)

Fungsi visualisasi dibangun menggunakan pustaka matplotlib dan seaborn untuk menampilkan pola sebaran lowongan kerja.

- **Insight Lokasi & Platform:** Berdasarkan grafik sebaran, peluang pekerjaan untuk sektor finansial tersentralisasi di wilayah ibu kota dan satelitnya, khususnya Jakarta Barat, Jakarta Timur, dan Tangerang Selatan. Hanya sedikit representasi dari luar pulau Jawa (seperti Palangkaraya dan Mataram).
- **Job Type & Experience:** Dari *dataset* yang telah dibersihkan, profil pemberi kerja umumnya menuntut kualifikasi "Penuh Waktu" dengan target pelamar setara minimal Sarjana (S1).



4.2 Analisis Teks (Frekuensi Kata)

Melakukan metode analisis teks parsial (pemotongan kalimat dan ekstraksi token) pada kolom `job_title` menggunakan *Counter*.

- **Insight Teks:** Tiga frasa kata terbanyak yang dicari oleh industri rekrutmen dalam kueri ini adalah "finance" (9 kemunculan), "accounting" (8 kemunculan), dan "tax" (6 kemunculan). Hal ini mengonfirmasi tren operasional bahwa perusahaan saat ini cenderung menggabungkan peran finansial umum dengan tugas audit/kepatuhan perpajakan di dalam satu posisi pekerjaan.

```
=== TOP 10 KATA PADA JUDUL LOWONGAN ===
```

```
finance           → 5x
accounting        → 4x
medical           → 1x
artificial         → 1x
intelligence       → 1x
engineer          → 1x
bagian            → 1x
keuangan          → 1x
```

```
=== RINGKASAN STATISTIK ===
```

```
Total lowongan      : 6
Platform sumber     : 2 (Karir.com, Glints)
Kota yang tercakup  : 4
Lowongan dengan gaji tercantum : 6
Lowongan tanpa gaji : 0
```

BAB 5 - KESIMPULAN

5.1 Rangkuman Pipeline

Proyek Akhir Analitika Big Data ini telah berhasil membuktikan kelayakan dan keandalan sebuah purwarupa sistem ETL dinamis dalam memetakan pasar tenaga kerja di Indonesia. Secara keseluruhan, *pipeline* rekayasa data yang dibangun sukses mendemonstrasikan penyelesaian terhadap tantangan multidimensi dari karakteristik Big Data, khususnya pada penyatuan aspek **Variety** dan standarisasi aspek **Veracity**.

Pada tahap akuisisi (*Extract*), sistem membuktikan kapabilitasnya dalam menarik data tak terstruktur dari dua ekosistem platform yang berbeda secara fundamental (Karir.com dan Glints.com). Pemanfaatan instrumen automasi Selenium terbukti esensial dan efektif untuk merender *JavaScript* dinamis serta mem-*bypass* protokol keamanan Cloudflare melalui metode penyamaran *User-Agent*. Sementara itu, kolaborasi dengan BeautifulSoup memungkinkan ekstraksi cerdas berbasis *Visual Order Scraping* dan *Heuristik Teks*.

Pada tahap pemrosesan (*Transform*), proyek ini berhasil menaklukkan hambatan *Veracity* dengan membersihkan data kotor (*dirty data*) bawaan platform menggunakan fungsi normalisasi string dan *missing values handling* via Pandas. Pada tahap akhir (*Load & Value*), *dataset* yang telah tervalidasi diubah menjadi *insight* bisnis melalui *Exploratory Data Analysis* (EDA), mengungkap tren sentralisasi geografis lowongan hingga frekuensi kata kunci industri.

5.2 Limitasi & Rekomendasi Pengembangan

- **Limitasi:** Struktur perisai anti-bot dari situs seperti Glints sangat adaptif dan dinamis. Skrip kode automasi antrean tunggu (*WebDriverWait*) seringkali memerlukan kalibrasi manual apabila infrastruktur *network* Google Colab mengalami latensi tinggi. Selain itu, sistem ekstraksi ini masih dijalankan secara sekuensial.
- **Rekomendasi:** Penggunaan infrastruktur "Headless Proxy Rotation" sangat direkomendasikan apabila skala ekstraksi (*Volume*) ingin ditingkatkan. *Dataset* terstandarisasi yang didapat dari *pipeline* ini ke depannya sangat siap untuk disuplai ke dalam arsitektur AI (misalnya pemodelan *Natural Language Processing* / NLP) guna menciptakan sistem *matching* otomatis antara *Curriculum Vitae* pelamar kerja dengan kualifikasi pada *job_requirements*.

LAMPIRAN

- **Repositori Project Lengkap (GitHub):**

<https://github.com/nadhif-royal/multi-platform-job-scraper-bigdata>

- **Kode Program (Notebook):**

<https://colab.research.google.com/drive/1K5mfPVfBW1EYzApHYgyvX5nFJsqPLuk0?usp=sharing>

- **Dataset Akhir:** cleaned_dataset_tahap2.csv (11 baris observasi, 11 fitur atribut).

<https://drive.google.com/file/d/10MIOWQrNKfp3cnTL1DNeMEZjckVLvWBi/view?usp=sharing>