

LAPORAN PROYEK AKHIR
Analisis Pasar Kerja Indonesia

Implementasi Big Data Pipeline



Oleh:

Nadhif Rif'at Rasendriya

235150201111074

UNIVERSITAS BRAWIJAYA
FAKULTAS ILMU KOMPUTER
2026

DAFTAR ISI

BAB 1 - PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Tujuan.....	2
1.3 Ruang Lingkup.....	2
BAB 2 - Implementasi: Pengumpulan Data (Extract).....	3
2.1 Alur Kerja Kode (Workflow).....	3
2.2 Dokumentasi Proses.....	4
Fase A: Ekstrak Lowongan AI Engineer.....	4
Fase B: Ekstrak Multi-Lowongan Finance.....	4
Fase C: Ekstrak Lowongan Finance dari Glints.....	5
Fase D: Ekstraksi Skala Massal via API (Aspek Volume).....	6
BAB 3 - Implementasi: Preprocessing & Veracity (Transform).....	8
3.1 Masalah Kualitas Data (Dirty Data).....	8
3.2 Teknik Data Cleaning yang Diterapkan.....	8
3.3 Perbandingan Sebelum dan Sesudah Cleaning.....	8
3.4 Filtering Spesifik Industri (Pandas Regex).....	9
BAB 4 - Implementasi: Analisis & Value (Exploratory Data Analysis).....	10
4.1 Signifikansi Skala Data terhadap Kualitas Analisis (EDA).....	10
4.2 Visualisasi Data Distribusi Pasar Kerja.....	10
4.3 Analisis Teks (Frekuensi Kata & Eksplorasi Keahlian).....	11
BAB 5 - KESIMPULAN.....	12
5.1 Rangkuman Pipeline.....	12
5.2 Limitasi & Rekomendasi Pengembangan.....	12
LAMPIRAN.....	13

BAB 1 - PENDAHULUAN

1.1 Latar Belakang

Di era digitalisasi saat ini, informasi pasar tenaga kerja telah bertransisi sepenuhnya dari media konvensional menuju portal lowongan kerja daring (*job portals*). Fenomena ini menciptakan tumpukan data rekrutmen yang sangat masif, yang secara potensial dapat dianalisis untuk memahami tren industri, permintaan keahlian (*skill demand*), hingga pemetaan kompensasi finansial secara makro. Namun, pemanfaatan data ini dihadapkan pada tantangan fragmentasi; informasi tersebar di berbagai platform yang saling terisolasi tanpa adanya standar format periklanan yang seragam.

Dari perspektif Analitika Big Data, tantangan ini secara langsung merepresentasikan karakteristik **Variety** (keanekaragaman sumber, struktur, dan format data) serta **Veracity** (tingkat kebersihan, konsistensi, dan validitas data). Secara teknis, platform modern pencari kerja terkemuka (seperti Karir.com dan Glints.com) menerapkan arsitektur web dinamis berbasis *Client-Side Rendering* (CSR) dengan *Document Object Model* (DOM) yang kerap diobfuskasi (*obfuscated*) atau diacak. Tingkat kerumitan bertambah dengan adanya sistem proteksi keamanan *Anti-Bot* berlapis (seperti *Cloudflare Turnstile*) di sisi server, yang menjadikan proses akuisisi data tidak bisa lagi dilakukan dengan metode *crawling* HTML statis tradisional.

Oleh karena itu, diperlukan sebuah arsitektur *pipeline* rekayasa data (*Data Engineering*) yang tangguh dan komprehensif. Proyek akhir ini digagas untuk merancang serta mengimplementasikan sistem ETL (*Extract, Transform, Load*) secara *end-to-end*. Sistem ini didesain untuk mampu melakukan *dynamic web scraping*, menembus proteksi keamanan antarmuka, mengekstraksi data semi-terstruktur dari *layout* yang berbeda, dan menyelaraskan anomali teks (*dirty data*) menjadi satu *master dataset* yang terstandardisasi. Hasil dari proses ini diharapkan dapat menjembatani jurang antara data mentah yang kotor di internet dengan wawasan (*actionable insights*) yang bernilai (*Value*).

1.2 Tujuan

Proyek akhir ini bertujuan untuk membangun sebuah purwarupa *pipeline* rekayasa data *end-to-end* (ETL - *Extract, Transform, Load*) guna mengotomatisasi pengumpulan, pembersihan, integrasi, hingga visualisasi data lowongan kerja dari dua platform yang memiliki struktur berbeda (Karir.com dan Glints.com).

1.3 Ruang Lingkup

- **Pengumpulan Data:** *Web scraping* dinamis untuk profil lowongan "Medical Artificial Intelligence (AI) Engineer" dan "Finance" di Karir.com dan Glints.com.
- **Pengolahan Data:** Menerapkan standardisasi untuk mengatasi *dirty data* (nilai kosong yang tidak seragam dan format numerik yang kotor).
- **Analisis Awal (EDA):** Menggali *insight* frekuensi kata kunci dan distribusi atribut melalui visualisasi data.

BAB 2 - Implementasi: Pengumpulan Data (*Extract*)

2.1 Alur Kerja Kode (Workflow)

Proses ekstraksi data ini menggunakan teknik *Web Scraping* dinamis dengan Selenium. Alur kerjanya adalah sebagai berikut:

1. **Inisialisasi Environment:** Menginstal library google colab selenium untuk menjalankan browser Chrome di server Google Colab tanpa memerlukan pengaturan manual Driver yang rumit.
2. **Navigasi Web:** Menggunakan Selenium untuk membuka URL spesifik dari Karir.com maupun Glints.com berdasarkan kata kunci pencarian.
3. **Pengolahan DOM:** Mengambil source code HTML halaman menggunakan `page_source` dan memprosesnya dengan BeautifulSoup.
4. **Ekstraksi Data (Visual Order Scraping):** Mengambil teks murni (`stripped_strings`) untuk menghindari kendala pada nama *class* HTML yang dinamis dan teracak.
5. **Pemetaan Atribut:** Mencocokkan teks yang didapat ke dalam 11 atribut wajib sesuai panduan teknis.
6. **Penyimpanan:** Mengonversi data ke dalam Pandas DataFrame dan mengeksportnya ke format CSV.

Alasan Pemilihan Metode (Selenium dan BeautifulSoup): Proses pengumpulan data tidak menggunakan metode API resmi (karena keterbatasan akses publik) atau metode *request* statis biasa (seperti library requests), melainkan menggunakan kombinasi Selenium dan BeautifulSoup dengan alasan teknis berikut:

- **Selenium untuk Penanganan Web Dinamis & Anti-Bot:** Platform modern seperti Karir.com dan Glints dibangun menggunakan framework JavaScript dinamis (seperti React). Konten detail lowongan (panel kanan) baru akan muncul ke dalam struktur HTML (DOM) setelah pengguna melakukan interaksi (klik) pada kartu lowongan di panel kiri. Selenium memungkinkan robot untuk menyimulasikan interaksi manusia (klik dan *scroll*) agar data muncul seutuhnya. Selain itu, Selenium dikonfigurasi dengan *User-Agent* khusus untuk menembus sistem proteksi Anti-Bot (seperti Cloudflare) yang sangat ketat pada situs Glints.


```

--- ○ Initialized Chromedriver
loading halaman Finance...
Berhasil mendeteksi 12 lowongan potensial.
Berhasil menarik data ke-1: Finance Staff - Mataram
Berhasil menarik data ke-2: Finance Accounting Tax Supervisor
Berhasil menarik data ke-3: Microsoft Dynamics 365 Finance - technical consultant
Berhasil menarik data ke-4: Microsoft Dynamics AX / 365 ERP Finance and Operations Technical Staff
Berhasil menarik data ke-5: Finance Staff

```

	job_title	company_name	location	job_type	experience_level	education_req	salary_range	job_requirements	job_responsibilities	posted_date	source_platform
1	Finance Staff - Mataram	PT Enseval Putera Megatrading, Tbk	Mataram	Tidak Disebutkan	-	S1 - Akuntansi	-	Bachelor's Degree of Accounting Experienced ...	Handling various tasks related to maintaining ...	27 Februari 2026	Karir.com
2	Finance Accounting Tax Supervisor	PT Enseval Putera Megatrading, Tbk	Jakarta Timur	Tidak Disebutkan	5 tahun	S1 - Akuntansi	Rp 10 juta - Rp 11 juta/bulan	Bachelor/Master degree from Accounting Exper...	Responsible for full function of Finance, Acco...	27 Februari 2026	Karir.com
3	Microsoft Dynamics 365 Finance - technical con...	PT Daya Medika Pratama	Jakarta Pusat	Tidak Disebutkan	4 tahun	S1, D3 - Administrasi Bisnis (Keuangan), Akunt...	-	2 years in the following skill set: 1.Dynami...	1)Provide technical consultancy to clients for...	27 Februari 2026	Karir.com
4	Microsoft Dynamics AX / 365 ERP Finance and Op...	PT Daya Medika Pratama	Bandung	Tidak Disebutkan	5 tahun	S2, S1, D3 - Administrasi Bisnis (Keuangan), A...	Rp 6 juta - Rp 13 juta/bulan	Microsoft Dynamics AX, D365 F&O, X++, SSRS/ Po...	Demonstrates strong coding skill using Dynamic...	27 Februari 2026	Karir.com
5	Finance Staff	PT Enseval Putera Megatrading, Tbk	Mataram	Tidak Disebutkan	-	S1 - Akuntansi	-	Bachelor's Degree of Accounting Experienced ...	Handling various tasks related to maintaining ...	27 Februari 2026	Karir.com


Pada kolom '**job_type**' tertulis 'Tidak disebutkan', hal tersebut terjadi karena pada informasi lowongan kerja (sumber asli) memang tidak disebutkan oleh pemilik lowongan.

Fase C: Ekstrak Lowongan Finance dari Glints

Fase ini bertujuan untuk memperluas jangkauan sumber data dengan mengambil informasi posisi "Finance" dari platform Glints.com.

- **Aktivitas:** Melakukan pencarian menggunakan kata kunci "Finance" dan lokasi "All Cities/Provinces" di Glints. Robot melakukan *looping* untuk mengklik dan mengekstrak data 5 lowongan teratas.
- **Kendala:**
 1. **Sistem Anti-Bot (Cloudflare):** Akses bot secara bawaan langsung diblokir oleh Glints dengan menampilkan halaman verifikasi "Just a moment..."
 2. **Struktur Web Tanpa Label:** Berbeda dengan Karir.com, Glints tidak menggunakan label teks (seperti "Tingkat Pendidikan:"), melainkan langsung menampilkan nilai dengan *icon* visual.
 3. **Teks Footer Masuk ke Data:** Karena metode mengambil seluruh teks di layar, atribut nama perusahaan sempat terisi teks hak cipta "© 2026 PT. Glints", dan lokasi terisi tombol "Kembali ke atas".
- **Solusi Tambahan:**
 - Menerapkan *User-Agent Spoofing* agar aktivitas robot dari Google Colab dikenali sebagai peramban Chrome Windows standar oleh Cloudflare.

- Menerapkan **Logika Heuristik Pintar**, yaitu mengenali data dari konteks kata (misal: jika mengandung kata "PT.", maka itu nama perusahaan; jika mengandung "tahun", maka itu pengalaman).
- Menerapkan **Teknik Isolasi/Mutilasi Teks**, di mana robot diprogram untuk menemukan letak judul di panel kanan, lalu secara otomatis "memotong" dan membuang teks menu panel kiri dan *footer* web bagian bawah agar ekstraksi tetap fokus.
- **Hasil:** Berhasil mengekstrak 5 baris lowongan kerja dari Glints.
- **Output:** raw_dataset_finance_glints.csv.



Fase D: Ekstraksi Skala Massal via API (Aspek *Volume*)

Penambahan fase ekstraksi terstruktur melalui antarmuka pemrograman atau *Application Programming Interface* (API) dilakukan secara khusus untuk membuktikan kapabilitas *pipeline* dalam menangani karakteristik **Volume** pada Big Data. Mengandalkan ekstraksi melalui antarmuka web (UI) menggunakan *browser automation* memiliki limitasi pada kecepatan dan rentan terhadap gangguan memori (seperti *Out of Memory* pada server). Oleh karena itu, ruang lingkup proyek diperluas dengan membangun koneksi langsung ke *endpoint* Arbeitnow Job Board API.

Secara teknis, implementasi ini memanfaatkan modul requests pada Python. Sistem diprogram untuk melakukan iterasi (*looping*) secara dinamis pada parameter page hingga

batas maksimal halaman yang ditentukan. Guna memastikan kelancaran ekstraksi dan mematuhi etika *crawling* (mencegah *server timeout* atau pemblokiran *rate-limiting* dari penyedia API), sistem disisipkan penanganan jeda waktu menggunakan fungsi `time.sleep()`. Pendekatan arsitektural ini terbukti sangat tangguh dan *scalable*, sukses mengakuisisi himpunan data berskala masif hingga mencapai 879 baris data lowongan kerja mentah hanya dalam hitungan detik.

Scraping page 1... Total sementara: 100 Scraping page 2... Total sementara: 200 Scraping page 3... Total sementara: 300 Scraping page 4... Total sementara: 400 Scraping page 5... Total sementara: 500 Scraping page 6... Total sementara: 600 Scraping page 7... Total sementara: 700 Scraping page 8... Total sementara: 800 Scraping page 9... Total sementara: 900 Scraping page 10... Total sementara: 949 Scraping page 11... Status gagal: 429 =====									
SCRAPING SELESAI TOTAL DATA: 879 =====									
	title	company	location	remote	tags	job_types	url	description	
0	E-Commerce Manager (m/w/d)	Sattler Media GmbH	Hildesheim	True	Remote, Trade Marketing	berufserfahren	https://www.arbebtnow.com/jobs/companies/sattl...	<p>Als E-Commerce-Manager-in bei der Sattler G...	
1	Prüfer hydraulischer Komponenten / Qualitätspr...	Flutronics GmbH	Krefeld	False	Engineering	berufserfahren	https://www.arbebtnow.com/jobs/companies/fluit...	<p>Sie arbeiten sorgfältig, technisch interess...	
2	Projektmanagerin Industry Department (m/w/d)	MEEvents Cross Media GmbH	Berlin	False	Project Management	berufserfahren	https://www.arbebtnow.com/jobs/companies/meven...	<p>Wissen vermehren, Mitglieder gewinnen, Kong...	
3	Personalsachbearbeiter (M/W/D) in Voll- Oder T...	Adula-Klinik Oberstdorf, Dr. Reisach GmbH & C...	Oberstdorf	False	HR		https://www.arbebtnow.com/jobs/companies/adula...	<p>Die Reisach Kliniken, Akutkliniken für Psyc...	
4	Frontend- / Web-Entwickler (w/m/d)	keyperformance GmbH	Cologne	False	Web Development	berufserfahren	https://www.arbebtnow.com/jobs/companies/keype...	<p>Wir suchen zum nächstmöglichen Zeitpunkt ei...	

BAB 3 - Implementasi: *Preprocessing & Veracity (Transform)*

Tahap pembersihan data ini difokuskan untuk menyelesaikan karakteristik **Veracity** pada Big Data, mengingat integrasi dari berbagai sumber otomatis mewariskan format penulisan yang tidak selaras (*dirty data*).

3.1 Masalah Kualitas Data (Dirty Data)

Dari tahap *Extract* (Pengumpulan Data), ketiga sumber data yang dikompilasi secara vertikal menyimpan anomali kualitas data pada *Master Dataset Mentah*:

1. **Format Missing Values Inkonsisten:** Terdapat variasi "N/A" dari Glints, "-" dari Karir.com, dan "Tidak Disebutkan".
2. **Kotoran Nominal Numerik:** Kolom gaji (*salary_range*) mengandung teks *hybrid* seperti "jt", spasi non-standar, atau penandaan "Gaji Tidak Ditampilkan" yang tidak terukur secara komputasi.

3.2 Teknik Data Cleaning yang Diterapkan

Kode program tambahan diimplementasikan menggunakan fungsi library Pandas dan NumPy:

- **Standardisasi Null:** Mengonversi seluruh wujud penanda kosong (seperti -, N/A, Tidak Disebutkan) menjadi format standar NaN (Not a Number).
- **Normalisasi Gaji:** Mengaplikasikan fungsi *custom* untuk mengganti token "jt" menjadi "juta", menghapus spasi anomali, dan menyeragamkan kalimat penolakan visibilitas gaji menjadi format seragam "Hidden by Employer".
- **Imputasi Pengalaman:** Memberlakukan pengisian format baku "Fresh Graduate / No Experience" untuk kolom level pengalaman (*experience_level*) yang kosong.

3.3 Perbandingan Sebelum dan Sesudah Cleaning

- **Sebelum (Raw Data):** Skema data tidak terpadu dan kotor. Data tidak valid jika diproses ke dalam model prediktif analitika maupun perangkat visualisasi.
- **Sesudah (Processed Data):** Menghasilkan berkas akhir *cleaned_dataset_tahap2.csv* di mana keseluruhan 11 kolom atribut telah terseragamkan. Kebenaran dan

konsistensi data (Veracity) kini dapat dipertanggungjawabkan untuk dianalisis lebih lanjut.

File 'cleaned_dataset_tahap2.csv' berhasil disimpan!												
	No	job_title	company_name	location	job_type	experience_level	education_req	salary_range	job_requirements	job_responsibilities	posted_date	source_platform
0	1	Medical Artificial Intelligence (AI) Engineer	PT Daya Medika Pratama	Bandung	Tidak Disebutkan	2 tahun	S2, S1 D3 - Ilmu Komputer, Manajemen Informatika...	Rp 6 juta - Rp 10 juta/bulan	Skills and Qualifications Technical Experts...	Responsibilities Design, develop, and implement...	9 Juni 2026	Karir.com
1	2	Finance Accounting & Tax	Minimal Diploma (D1 - D4)	Kab. Bekasi	Penuh Waktu	1-3 tahun	Minimal Diploma (D1 - D4)	Gaji Tidak Ditampilkan	NaN	NaN	Baru (< 2 minggu)	Glints
2	3	Finance Accounting & Tax	Minimal Diploma (D1 - D4)	Kab. Bekasi	Penuh Waktu	1-3 tahun	Minimal Diploma (D1 - D4)	Gaji Tidak Ditampilkan	NaN	NaN	Baru (< 2 minggu)	Glints
3	4	Finance / Bagian Keuangan	Minimal Sarjana (S1)	Jakarta Barat	Kontrak	1-3 tahun	Minimal Sarjana (S1)	Rp 5 juta-7 juta	NaN	NaN	Baru (< 2 minggu)	Glints
4	5	Manager Finance Accounting & Tax	Minimal Sarjana (S1)	Semarang	Penuh Waktu	3-5 tahun	Minimal Sarjana (S1)	Rp 5 juta	NaN	NaN	Baru (< 2 minggu)	Glints
5	6	Manager Finance Accounting Tax	Minimal Sarjana (S1)	Jakarta Barat	Kontrak	1-3 tahun	Minimal Sarjana (S1)	Rp 10 juta-12 juta	NaN	NaN	Baru (< 2 minggu)	Glints

3.4 Filtering Spesifik Industri (Pandas *Regex*)

Dari 879 baris data mentah yang berhasil diekstrak melalui jaringan API, diperlukan penyaringan (*filtering*) untuk mengeliminasi *noise* berupa lowongan pekerjaan di luar industri target (seperti medis, perhotelan, dsb.). Untuk mengatasi hal ini, diterapkan teknik penyaringan tingkat lanjut menggunakan pustaka Pandas.

Proses penyaringan dilakukan pada kolom title dengan mengimplementasikan fungsi `.str.contains()`. Fungsi ini dikonfigurasi menggunakan pola *Regular Expression* (Regex) dengan memanfaatkan operator logika OR (`|`) untuk menggabungkan belasan kata kunci target sekaligus, seperti "AI", "Data", "Machine Learning", "Software", "Finance", "Business", hingga "Product". Dengan mengatur parameter `case=False` agar pencarian bersifat tidak sensitif terhadap huruf kapital (*case-insensitive*), sistem secara otonom memindai dan membuang data yang tidak relevan. Hasil dari tahapan transformasi ini adalah reduksi data kotor menjadi 169 baris dataset final yang secara eksklusif hanya berisi profil lowongan pada sektor teknologi dan bisnis/finansial.

```
df_filtered = df_massal[
    df_massal["title"].str.contains(
        pattern,
        case=False,
        na=False
    )
]

print("Jumlah data setelah filtering:", len(df_filtered))

display(df_filtered.head())
```

	title	company	location	remote	tags	job_types	url	description
4	Frontend- / Web-Entwickler (w/m/d)	keyperformance GmbH	Cologne	False	Web Development	berufserfahren	https://www.arbeItnow.com/jobs/companies/keype...	<p>Wir suchen zum nächstmöglichen Zeitpunkt et...
14	(Senior) Technical Product Manager, Rail Integ...	Distribution Technologies	Berlin	False	Information technology, bachelor's degree	Full-time permanent, experienced	https://www.arbeItnow.com/jobs/companies/distr...	<p>Distribution is the world...
19	Software Engineer, Data Infrastructure & Acqui...	Speechify	Germany	False			https://www.arbeItnow.com/jobs/companies/speec...	<p>The mission of Speechify is to make sure th...
20	Senior Software Engineer, Windows/Desktop Appl...	Speechify	Germany	False			https://www.arbeItnow.com/jobs/companies/speec...	<div class="p-rich_text_section"><strong data...
21	Software Engineer, iOS Core Product	Speechify	Germany	False			https://www.arbeItnow.com/jobs/companies/speec...	<p>The mission of Speechify is to make sure th...

BAB 4 - Implementasi: Analisis & Value (*Exploratory Data Analysis*)

4.1 Signifikansi Skala Data terhadap Kualitas Analisis (EDA)

Karakteristik **Value** pada Big Data ditunjukkan dari kemampuan mengubah tumpukan data berkapasitas besar menjadi wawasan (*insight*) bisnis. Dengan terintegrasinya ratusan himpunan data berskala masif hasil akuisisi API dan penyaringan Regex, wawasan yang dihasilkan dari tahapan *Exploratory Data Analysis* (EDA) kini memiliki tingkat representasi dan akurasi statistik yang jauh melebihi sampel data awal.


Analisis pasar kerja dalam proyek ini tidak lagi bersifat asumtif atau terbatas pada sampel kecil, melainkan mampu memotret tren rekrutmen industri, distribusi lokasi pekerjaan hibrida/jarak jauh (*remote*), hingga kombinasi keahlian yang paling banyak diminta (*skill tags*) secara komprehensif. Basis data yang masif ini menjadikan hasil visualisasi sebagai landasan yang sangat solid dan meyakinkan untuk pengambilan keputusan berbasis data (*data-driven decision making*).

4.2 Visualisasi Data Distribusi Pasar Kerja

Fungsi visualisasi dibangun secara analitis menggunakan pustaka matplotlib dan seaborn untuk menampilkan pola sebaran lowongan kerja dari *dataset* yang telah dibersihkan.

- **Insight Lokasi & Model Kerja:** Berdasarkan grafik sebaran pada data lokal, peluang pekerjaan tersentralisasi secara padat di wilayah ibu kota dan daerah satelitnya, khususnya Jakarta Barat, Jakarta Timur, dan Tangerang Selatan. Hanya terdapat sedikit representasi dari luar pulau Jawa (seperti Palangkaraya dan Mataram). Di sisi lain, integrasi dataset API skala besar memperlihatkan tren alternatif berupa tingginya adopsi model kerja *remote* (jarak jauh) pada sektor teknologi.
- **Job Type & Experience:** Dari dataset terpadu, profil pemberi kerja umumnya secara tegas menuntut kualifikasi tipe pekerjaan "Penuh Waktu" (*Full-Time*) dengan target pelamar yang setara minimal pendidikan Sarjana (S1) dan memiliki rekam jejak pengalaman yang relevan.

Analisis Pasar Kerja Indonesia Karir.com & Glints — Februari/Maret 2026



4.3 Analisis Teks (Frekuensi Kata & Eksplorasi Keahlian)

Selain analisis kategorikal, proyek ini mengeksplorasi wawasan berbasis teks dengan melakukan pemotongan kalimat dan ekstraksi token (menggunakan library Counter) pada fitur spesifik seperti job_title dan tags.

- Insight Teks (Kata Kunci Industri):** Tiga frasa kata terbanyak yang dicari oleh industri rekrutmen dalam kueri sektoral adalah "finance", "accounting", dan "tax". Temuan ini mengonfirmasi tren operasional bahwa entitas bisnis modern cenderung meleburkan peran manajerial finansial umum dengan tugas audit dan kepatuhan perpajakan ke dalam satu posisi tunggal yang komprehensif.

```

=== TOP 10 KATA PADA JUDUL LOWONGAN ===
finance      → 5x
accounting   → 4x
medical      → 1x
artificial   → 1x
intelligence → 1x
engineer     → 1x
bagian       → 1x
keuangan     → 1x

=== RINGKASAN STATISTIK ===
Total lowongan      : 6
Platform sumber     : 2 (Karir.com, Glints)
Kota yang tercakup  : 4
Lowongan dengan gaji tercantum : 6
Lowongan tanpa gaji      : 0
  
```

BAB 5 - KESIMPULAN

5.1 Rangkuman Pipeline

Proyek Akhir Analitika Big Data ini telah berhasil membuktikan kelayakan dan keandalan sebuah purwarupa sistem ETL dinamis dalam memetakan pasar tenaga kerja di Indonesia. Secara keseluruhan, *pipeline* rekayasa data yang dibangun sukses mendemonstrasikan penyelesaian terhadap tantangan multidimensi dari karakteristik Big Data, khususnya pada penyatuan aspek **Variety** dan standarisasi aspek **Veracity**.

Pada tahap akuisisi (*Extract*), sistem membuktikan kapabilitasnya dalam menarik data tak terstruktur dari dua ekosistem platform yang berbeda secara fundamental (Karir.com dan Glints.com). Pemanfaatan instrumen automasi Selenium terbukti esensial dan efektif untuk merender *JavaScript* dinamis serta mem-*bypass* protokol keamanan Cloudflare melalui metode penyamaran *User-Agent*. Sementara itu, kolaborasi dengan BeautifulSoup memungkinkan ekstraksi cerdas berbasis *Visual Order Scraping* dan *Heuristik Teks*.

Pada tahap pemrosesan (*Transform*), proyek ini berhasil menaklukkan hambatan *Veracity* dengan membersihkan data kotor (*dirty data*) bawaan platform menggunakan fungsi normalisasi string dan *missing values handling* via Pandas. Pada tahap akhir (*Load & Value*), *dataset* yang telah tervalidasi diubah menjadi *insight* bisnis melalui *Exploratory Data Analysis* (EDA), mengungkap tren sentralisasi geografis lowongan hingga frekuensi kata kunci industri.

5.2 Limitasi & Rekomendasi Pengembangan

- **Limitasi:** Struktur perisai anti-bot dari situs seperti Glints sangat adaptif dan dinamis. Skrip kode automasi antrean tunggu (*WebDriverWait*) seringkali memerlukan kalibrasi manual apabila infrastruktur *network* Google Colab mengalami latensi tinggi. Selain itu, sistem ekstraksi ini masih dijalankan secara sekuensial.
- **Rekomendasi:** Penggunaan infrastruktur "Headless Proxy Rotation" sangat direkomendasikan apabila skala ekstraksi (*Volume*) ingin ditingkatkan. *Dataset* terstandarisasi yang didapat dari *pipeline* ini ke depannya sangat siap untuk disuplai ke dalam arsitektur AI (misalnya pemodelan *Natural Language Processing* / NLP) guna menciptakan sistem *matching* otomatis antara *Curriculum Vitae* pelamar kerja dengan kualifikasi pada *job_requirements*.

LAMPIRAN

- **Repositori Project Lengkap (GitHub):**

<https://github.com/nadhif-royal/multi-platform-job-scraper-bigdata>

- **Kode Program (Notebook):**

<https://colab.research.google.com/drive/1K5mfPVfBW1EYzApHYgyvX5nFJsqPLuk0?usp=sharing>

- **Dataset Akhir:** cleaned_dataset_tahap2.csv (11 baris observasi, 11 fitur atribut).

<https://drive.google.com/file/d/10MIOWQrNKfp3cnTL1DNeMEZjckVLvWBi/view?usp=sharing>